Separación de funciones entre código determinístico y modelos generativos en reportería financiera: resultados de un backtest de ocho trimestres

Ignacio Lopez
Work-Smart.ai · Miami, Florida, Estados Unidos
ignacio@work-smart.ai

Resumen — La discusión sobre inteligencia artificial en la empresa suele girar alrededor de la precisión del modelo. En reportería financiera regulada la pregunta pertinente es otra: qué componente tiene permitido calcular. Este trabajo describe una arquitectura de separación de funciones —todo lo que debe ser numéricamente correcto se escribe como código determinístico, y el modelo generativo solo lee, señala y deriva a una persona nombrada— y la somete a una prueba empírica poco frecuente en la literatura de adopción: un backtest campo por campo contra ocho trimestres de reportes ya firmados por el cliente. El diseño incorpora una advertencia metodológica que invalida el criterio de éxito intuitivo. El motor lee el libro mayor de hoy; los reportes firmados se armaron con el libro mayor del día de la firma, y entre ambas fechas hubo reexpresiones contables legítimas. Reproducir los ocho trimestres no sería una virtud sino una señal de que el sistema ignora esas correcciones. El criterio correcto es que el único trimestre cuyo libro mayor no fue tocado después de firmar coincida al centavo, y coincide. El hallazgo de mayor valor, sin embargo, no fue una coincidencia sino una negativa: el motor se detuvo y no publicó un trimestre porque sus dos vías independientes de cálculo no cerraron. La causa no estaba en el software sino en las fuentes, y afectaba por igual al armado manual en planilla. Se documentan la taxonomía de diferencias, los límites conocidos y el control más barato que otra organización puede aplicar mañana.

Palabras clave — *gobernanza de IA, reportería financiera, control interno, separación de funciones, backtest, calidad de datos.*

Eje temático propuesto — ROI: Operaciones y Automatización (caso real, con datos).

Abstract — Enterprise discussion of artificial intelligence tends to centre on model accuracy. In regulated financial reporting the relevant question is different: which component is permitted to calculate. This paper describes a separation-of-duties architecture — anything that must be numerically correct is written as deterministic code, and the generative model only reads, flags and routes to a named human — and subjects it to an empirical test that is uncommon in the adoption literature: a field-by-field backtest against eight quarters of reports the client had already signed. The design carries a methodological caveat that invalidates the intuitive success criterion. The engine reads today's general ledger; the signed reports were built from the general ledger as it stood on the signing date, and legitimate accounting restatements occurred in between. Reproducing all eight quarters would not be a virtue but a signal that the system ignores those corrections. The correct criterion is that the one quarter whose ledger was untouched after signing must match to the cent, and it does. The most valuable finding, however, was not a match but a refusal: the engine halted and declined to publish one quarter because its two independent calculation paths failed to reconcile. The cause lay in the source files rather than the software, and it affected manual spreadsheet assembly equally. The paper documents the difference taxonomy, the known limits, and the cheapest control another organisation can apply tomorrow.

Keywords — *AI governance, financial reporting, internal control, separation of duties, backtest, data quality.*

I. INTRODUCCIÓN

La mayor parte de los programas de inteligencia artificial en la empresa discuten si el modelo es lo bastante preciso. Esa es la segunda pregunta. La primera, en cualquier proceso cuyo resultado va a ser firmado por alguien, es más simple y más incómoda: qué componente del sistema tiene permitido calcular una cifra.

La regla que se aplica en las implementaciones descritas aquí es una sola. Todo lo que debe ser numéricamente correcto se escribe como código determinístico. Un modelo generativo que se equivoca con confianza sobre un número es peor que la ausencia de modelo, porque el error llega con la misma prosa segura que el acierto. El modelo se usa donde efectivamente es fuerte: leer registros, detectar anomalías, resumir excepciones y derivarlas a una persona nombrada. El circuito humano existe siempre, y está documentado, porque en un entorno regulado un control no documentado equivale a la ausencia de control.

Esa arquitectura es fácil de enunciar y difícil de evidenciar. La literatura de adopción abunda en descripciones de despliegue y escasea en verificación contra una línea de base independiente. Este trabajo aporta esa verificación: un backtest campo por campo de un motor de reportería trimestral contra ocho trimestres de reportes que el cliente ya había firmado y distribuido a sus inversores.

El resultado que más importa no es el porcentaje de coincidencia. Es que en uno de los ocho trimestres el motor se negó a publicar, y la razón de esa negativa era un defecto real en los archivos de origen que el proceso manual previo no había detectado. Un sistema que confirma lo que ya se sabía aporta poco. Uno que se frena cuando algo no cierra aporta el control que el proceso no tenía.

II. ANTECEDENTES, RETOS Y PROBLEMAS

A. El proceso previo

El caso corresponde a un portafolio de activos de retail administrado por un grupo inmobiliario con operación en Estados Unidos. El circuito de reportería trimestral a inversores partía de un ERP inmobiliario comercial, del cual se exportaba el libro mayor a planilla, y desde allí una persona armaba manualmente el estado de resultados, la ocupación y el comentario de variaciones, para producir un documento que luego se firmaba.

Ese circuito tiene tres problemas que no son particulares de esta organización. El primero es que el conocimiento del armado vive en una persona. El segundo es que no existe traza: el documento firmado no lleva adentro la ruta desde la cuenta contable hasta la cifra publicada. El tercero, y el que este trabajo termina iluminando, es que la calidad de los archivos de origen se asume en lugar de comprobarse.

B. Por qué el modelo no debe calcular

Los modelos de lenguaje son herramientas de reconocimiento y generación de patrones, no calculadoras auditables. Producen una cifra plausible sin dejar una traza reproducible de cómo la obtuvieron, y su comportamiento puede variar entre versiones del mismo modelo. Ninguna de esas propiedades es aceptable en una cifra que va a ser firmada.

Los marcos de control vigentes empujan en la misma dirección aunque no lo digan en estos términos. La lógica de control interno sobre reportería financiera exige que un control sea repetible, documentado y con responsable identificable [1], [2]. Los marcos específicos de gestión de inteligencia artificial incorporan de forma explícita la supervisión humana, la trazabilidad y la gestión del riesgo del sistema [3], [4]. Un motor determinístico satisface el primer conjunto de requisitos por construcción; un modelo generativo colocado sobre la salida, y no dentro del cálculo, satisface el segundo sin comprometer el primero.

III. METODOLOGÍA APLICADA

A. Arquitectura

El sistema separa tres funciones. El cálculo lo ejecuta un motor determinístico que lee el libro mayor exportado del ERP y aplica un mapa de cuentas explícito. La revisión la ejecuta un modelo generativo que no accede al cálculo: recibe la salida, la contrasta contra el presupuesto y contra el trimestre anterior, y emite señales. La decisión la toma una persona nombrada, sobre las señales, antes de que el reporte se publique.

Dos mecanismos de control están embebidos en el motor y son los que producen los resultados de la sección IV.

> El primero es el cálculo del resultado operativo neto por dos vías independientes. Si las dos vías no cierran, el motor no publica. No estima, no completa el faltante y no emite una cifra parcial: bloquea el reporte y explica por qué.
>
> El segundo es el mapa de cuentas explícito, de 74 cuentas en la implementación evaluada. Una cuenta que no está en el mapa se marca como no mapeada y detiene la publicación. No se descarta en silencio, que es el modo de falla habitual de los procesos en planilla.

B. Diseño del backtest

Se corrieron ocho trimestres consecutivos, de 2024-Q3 a 2026-Q2, contra los reportes firmados del mismo período, comparando campo por campo: ocupación, ingresos y resultado operativo neto.

C. La advertencia metodológica que cambia el criterio de éxito

El motor lee el libro mayor de hoy. Los reportes firmados se armaron con el libro mayor del día en que se firmaron. Entre esas dos fechas la organización realizó reconciliaciones de gastos recuperables y reimputaciones contables, que son trabajo normal y correcto.

La consecuencia es que un trimestre reexpresado después de firmarse no puede reproducirse exactamente, y no debería. Si el motor devolviera la cifra antigua estaría ignorando las correcciones posteriores. Por lo tanto, el criterio de éxito no es la coincidencia en los ocho trimestres. El criterio es más estrecho y más exigente:

> **El único trimestre cuyo libro mayor no fue modificado después de la firma debe coincidir al centavo. Los demás deben tener cada diferencia explicada y trazada hasta la cuenta que la origina, y ninguna diferencia debe provenir del cálculo.**

Enunciar este criterio antes de correr la prueba es parte del método. Un backtest cuyo criterio de éxito se define después de ver los resultados no es una verificación.

D. Auditoría de la ventana de las fuentes

Como control adicional se revisaron los dieciocho exports de libro mayor disponibles de dos ejercicios, comparando el rango de fechas que cada archivo declara en su propio encabezado. Este control no estaba previsto en el diseño original y se incorporó al investigar el trimestre bloqueado.

E. Reproducibilidad

Otra organización puede replicar este procedimiento con cuatro insumos: los exports de libro mayor del período, los reportes firmados correspondientes, un mapa de cuentas explícito y versionado, y una segunda vía de cálculo del indicador principal que sea independiente de la primera. No se requiere infraestructura de modelos: el backtest es un ejercicio determinístico. El componente generativo interviene después, sobre la salida ya calculada.

IV. RESULTADOS

A. Comparación campo por campo

La ocupación coincidió de forma exacta en los ocho trimestres. El resultado operativo neto se emitió en seis de los ocho. Los ingresos coincidieron de forma exacta en cuatro de los siete trimestres en los que el motor los emitió; en los tres restantes la diferencia fue de +0,7719 %, −0,0101 % y −0,0002 % de los ingresos del trimestre, y en los tres quedó trazada hasta la cuenta que la origina. Véase la Tabla I. Por confidencialidad del cliente las magnitudes se expresan como diferencia relativa sobre los ingresos del trimestre y no en valores absolutos.

Tabla I. Diferencias entre el reporte firmado y la salida del motor, ocho trimestres

Trimestre	Δ Ingresos (% ingresos)	Δ NOI (% ingresos)	Δ Gasto operativo	Estado del NOI
2024-Q3	—	—	—	No emitido (layout previo)
2024-Q4	0,0000 %	+2,1384 %	−2,1384 %	Emitido
2025-Q1	+0,7719 %	+0,7719 %	0,0000 % exacto	Emitido
2025-Q2	−0,0101 %	+0,1093 %	−0,1193 %	Emitido
2025-Q3	0,0000 %	+2,4886 %	−2,4886 %	Emitido
2025-Q4	—	—	—	Bloqueado por el motor
2026-Q1	0,0000 %	0,0000 %	0,0000 % exacto	Emitido · coincidencia exacta
2026-Q2	−0,0002 %	−0,0002 %	0,0000 % exacto	Emitido · reproduce el firmado

Nota: todas las magnitudes se expresan como diferencia relativa sobre los ingresos del trimestre. «0,0000 % exacto» indica que el gasto operativo cuadró al centavo y, por lo tanto, que la diferencia del resultado operativo neto proviene enteramente de ingresos. El signo positivo indica que la salida del motor es mayor que el reporte firmado.

Dos trimestres reproducen el reporte firmado. El 2026-Q1 coincide de forma exacta en ocupación, ingresos y resultado operativo neto, y es el trimestre cuyo libro mayor no fue reexpresado después de la firma: es la prueba de corrección del motor definida en la sección III-C. El 2026-Q2 alcanza una diferencia de −0,0002 % de los ingresos, con el gasto operativo cuadrando al centavo, después de que el cliente reclasificara una cuenta en su propio ERP durante el período de prueba.

B. El hallazgo principal: una negativa a publicar

El motor se negó a publicar el 2025-Q4. Las dos vías independientes de cálculo del resultado operativo neto no cerraron, y el sistema bloqueó el reporte en lugar de emitir una cifra.

Al investigar la causa se revisaron los rangos de fechas declarados por cada export de libro mayor. A partir de junio de 2025, trece exports consecutivos declaran exactamente siete meses: el mes del reporte más los seis anteriores. Un solo archivo rompe el patrón, y es precisamente el archivo con el que se cierra el trimestre en cuestión. Véase la Tabla II.

Tabla II. Rango declarado por los exports de libro mayor

Export de GL	Rango declarado en el encabezado	Meses
2025.10	04/25 → 10/25	siete
2025.11	05/25 → 11/25	siete
2025.12	**11/25 → 12/25**	**dos**
2026.01	07/25 → 01/26	siete
2026.06	12/25 → 06/26	siete

Nota: se muestran cinco de los dieciocho exports revisados. El export de cierre de ejercicio declara dos meses donde sus trece vecinos consecutivos declaran siete.

La consecuencia es concreta y no depende de la tecnología empleada. Cualquier proceso que arme ese trimestre a partir de ese único archivo pierde un mes de movimientos. Vale para el motor y vale para el armado manual en planilla, que es como el trimestre se había armado y firmado. Los movimientos del mes faltante existen —están en los exports de los meses anterior y posterior— pero no en el archivo con el que se cerró el trimestre.

El comportamiento observado es el que se busca de un sistema de este tipo. No completó el hueco, no estimó, no publicó un indicador incompleto: se detuvo y avisó.

C. Taxonomía de las diferencias

Todas las diferencias de resultado operativo neto en los trimestres emitidos corresponden a reexpresión de cuentas de gastos recuperables —limpieza, retiro de residuos, paisajismo, ascensores y seguridad— es decir, a las reconciliaciones que la organización realizó después de firmar.

Ninguna diferencia provino de una cuenta sin clasificar y ninguna provino de un error de cálculo. En el 2025-Q1, tras corregir la lectura de períodos, el gasto operativo cuadra de forma exacta y la totalidad de la diferencia del trimestre es reexpresión de ingresos.

D. Calidad de las señales del componente generativo

En la corrida del trimestre en curso el sistema emitió 62 señales, de las cuales 3 correspondían a verificaciones satisfactorias y ninguna a una condición crítica. Un ejemplo ilustra el nivel al que el sistema deja el trabajo para que una persona decida.

Una cuenta de equipamiento y software informático apareció en cero contra un presupuesto asignado, con una caída del 100 % respecto del trimestre anterior: dos alertas simultáneas. Al abrirlas, la licencia anual del ERP y una comisión asociada se habían imputado a fin de febrero. El ejercicio anterior la misma factura había entrado en abril, es decir, en el trimestre siguiente. No faltaba un gasto: la factura entró un trimestre antes que el año previo y el presupuesto había quedado donde caía históricamente. La acción correcta no es tocar el libro mayor sino mover ese renglón del presupuesto.

Ese es el rol del componente generativo en esta arquitectura. No calcula, no corrige y no decide. Reduce un libro mayor completo a una lista corta de cosas que una persona debe mirar, con el contexto suficiente para que la decisión tome minutos en lugar de horas.

E. Límites conocidos

Se documentan aquí porque un resultado sin límites declarados no es un resultado.

El trimestre más antiguo evaluado no produjo resultado operativo neto: el reporte de ese período usa una estructura de plantilla anterior a la vigente, sobre la cual el motor extrae ocupación e ingresos pero no reconstruye el estado de resultados. Es una limitación conocida y acotada a un ejercicio.

El mapa de 74 cuentas cubre de forma completa los exports de mitad de trimestre: siete de los ocho trimestres tuvieron cero cuentas sin mapear. Los exports de cierre de ejercicio incorporan alrededor de veinticuatro cuentas adicionales que el mapa aún no cubre. El motor las marca y detiene la publicación; no las descarta. Resolverlo es una sesión de clasificación con el área contable, no un problema del motor.

La reconciliación factura por factura quedó incompleta por ausencia de una fuente auxiliar del período, no por una limitación del método.

El diseño no permite distinguir, a partir de la diferencia sola, entre una reexpresión contable legítima y un error histórico real. Esa distinción requiere el libro mayor en el momento de la firma, que no siempre se conserva. Es la limitación más importante de este trabajo y la que un estudio posterior debería atacar con versionado de fuentes.

V. CONCLUSIONES

El valor de separar el cálculo determinístico de la revisión generativa no se demuestra en la precisión. Se demuestra en la negativa. Un sistema que emite siempre una cifra traslada al lector la carga de descubrir cuándo esa cifra es incompleta. Un sistema que bloquea la publicación cuando dos vías independientes no cierran convierte un defecto silencioso en un evento visible, con fecha y con responsable.

El hallazgo de mayor valor de este backtest no fue sobre el software sino sobre las fuentes, y afectaba por igual al proceso manual que el software vino a reemplazar. Esto sugiere una inversión del orden habitual de los proyectos de inteligencia artificial en la empresa: antes de evaluar modelos conviene auditar la ventana temporal que declaran los archivos con los que se cierran los períodos. Es el control más barato disponible y, en el caso evaluado, el único que habría evitado publicar un trimestre incompleto.

La contribución práctica se resume en cuatro puntos transferibles a cualquier organización que produzca reportería periódica: calcular el indicador principal por dos vías independientes y no publicar si no cierran; mantener un mapa de cuentas explícito que detenga la publicación ante lo desconocido en lugar de descartarlo; verificar el rango declarado por

los archivos de origen del período de cierre; y correr el sistema nuevo en paralelo al proceso manual durante al menos un período completo, de modo que la confianza se gane con evidencia y no con una promesa.

Este trabajo no afirma que la arquitectura descrita sea generalizable sin más. Corresponde a un activo, un ERP y un portafolio. Lo que sí afirma, con la evidencia de ocho trimestres, es que el criterio de éxito con el que habitualmente se evalúan estos sistemas —cuántas veces coinciden— es el criterio equivocado, y que el criterio correcto es más estrecho, más difícil de satisfacer y considerablemente más útil.

VI. BIOGRAFÍA

Ignacio Lopez es fundador de Work-Smart.ai, donde se desempeña como Fractional Head of AI para family offices, multi-family offices y firmas de wealth management. Comenzó su carrera en KPMG como auditor de SOX en trabajos de privacidad de datos para empresas públicas, y posteriormente fue information risk manager en JP Morgan. Más tarde desarrolló producto en un laboratorio de innovación en Silicon Valley y lideró producto en una compañía global de software. Estudió ciencias de la computación, ha fundado tres empresas, reside en Miami y trabaja en inglés y español.

LinkedIn: linkedin.com/in/ignaciolopez2017

AGRADECIMIENTOS

El autor agradece al equipo de finanzas y contabilidad de la organización evaluada, cuya disposición a que se contrastaran públicamente sus propios reportes firmados hizo posible este trabajo. Los datos se presentan de forma anonimizada y las magnitudes monetarias absolutas se han omitido por acuerdo de confidencialidad.

REFERENCIAS

[1] Committee of Sponsoring Organizations of the Treadway Commission, Internal Control — Integrated Framework, 2013.

[2] Sarbanes-Oxley Act of 2002, Pub. L. No. 107-204, §404, «Management Assessment of Internal Controls», Estados Unidos, 2002.

[3] ISO/IEC 42001:2023, Information technology — Artificial intelligence — Management system, International Organization for Standardization, Ginebra, 2023.

[4] National Institute of Standards and Technology, Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1, Gaithersburg, MD, 26 de enero de 2023. DOI: 10.6028/NIST.AI.100-1.