95% de los proyectos de IA fracasan, no por la tecnología, sino por la implementación

Pablo Carmona[1]

[1] Itera & Beta AI, Ciudad de México, México

pablo@b-ta.ai · https://www.linkedin.com/in/pblcrmn · +52 55 1066 0830

Resumen — La mayoría de las iniciativas de inteligencia artificial en empresas no fracasan por falta de modelos o herramientas, sino por fallas de implementación: equipos sin ownership de entrega, ritmos de actualización incompatibles con el aprendizaje del producto, y métricas de «vanity AI» que no se conectan con resultados de negocio. Este artículo presenta un marco práctico orientado a product managers y líderes de producto para diagnosticar y corregir esas tres causas. A partir de experiencia en contextos de product, branding y change en compañías como Rappi, Mercado Pago, Wise y Bolt, se propone: (1) diseñar el equipo que implementa —roles, incentivos y decisiones que pasan de piloto a producción; (2) definir un ritmo de updates que sostenga adopción y aprendizaje continuo; y (3) sustituir indicadores cosméticos de IA por métricas de negocio y de producto accionables. El trabajo aporta una checklist de implementación, criterios de priorización y señales tempranas de fracaso útiles para organizaciones en Latinoamérica que buscan pasar de demos a impacto. Las conclusiones enfatizan que la ventaja competitiva no está en el modelo más nuevo, sino en la capacidad operativa de integrar IA en el sistema de producto.

Abstract — Most enterprise AI initiatives fail not because of weak models or tooling, but because of implementation: unclear delivery ownership, update cadences that cannot sustain learning, and vanity AI metrics disconnected from business outcomes. This paper offers a practical framework for product managers and product leaders to address those three failure modes. Drawing on product, branding, and change work across companies such as Rappi, Mercado Pago, Wise, and Bolt, it argues for (1) staffing and incentivizing the team that ships—not only the team that explores; (2) an update rhythm that compounds adoption; and (3) replacing cosmetic AI KPIs with actionable product and business metrics. The contribution is an implementation checklist, prioritization criteria, and early-warning signals tailored to organizations in Latin America moving from demos to durable impact. Competitive advantage, we conclude, comes less from the newest model than from the operating system that embeds AI into the product.

I. INTRODUCCIÓN

Las organizaciones enfrentan una paradoja aparente: acceso sin precedentes a modelos de inteligencia artificial generativa y predictiva y, al mismo tiempo, una tasa elevada de proyectos que no llegan a producción o que llegan sin mover el P&L. Informes de industria y evidencia anecdótica en Latinoamérica coinciden en un patrón: el cuello de botella rara vez es «falta de tecnología»; es la ausencia de un sistema de implementación que conecte exploración técnica con ownership de producto, ritmo de releases y métricas que el negocio reconoce [1], [2].

Este artículo se dirige a product managers y product leaders —roles que suelen heredar la narrativa de «transformación con IA» sin heredar el control sobre incentivos, capacidad de engineering ni definición de éxito. La tesis es directa: aproximadamente nueve de cada diez iniciativas se estancan no por el modelo, sino por tres fallas recurrentes de implementación: (a) un equipo que explora sin un equipo que implementa; (b) un ritmo de updates incompatible con el aprendizaje del producto; y (c) tableros de «vanity AI» que sustituyen a las métricas de negocio.

El trabajo se organiza en cinco bloques. La sección II sitúa antecedentes y retos a partir de literatura de productividad, product discovery y adopción organizacional. La sección III describe una metodología aplicada reproducible: diseño del equipo de implementación, cadencia de updates y sistema de métricas «usar / evitar». La sección IV presenta resultados en forma de patrones cualitativos derivados de experiencia en contextos de product, branding y change con empresas como Rappi, Mercado Pago, Wise y Bolt, junto con una tabla de señales y una figura del flujo piloto→producción. La sección V sintetiza conclusiones, limitaciones y trabajo futuro.

El aporte no es un nuevo algoritmo, sino un marco operativo para pasar de demos a impacto. En mercados LATAM —donde presupuestos, talento y tolerancia al riesgo suelen ser más ajustados que en Silicon Valley— la disciplina de implementación es, en la práctica, la única ventaja sostenible [3].

II. ANTECEDENTES, RETOS Y PROBLEMAS

La literatura sobre IA y productividad advierte desde hace años que el valor no aparece automáticamente con la adopción de herramientas: requiere complementos organizacionales —procesos, habilidades, datos y rediseño de trabajo— [1], [4]. En paralelo, la práctica de producto distingue discovery (aprender qué construir) de delivery (llevar valor a usuarios), y advierte que equipos «feature factories» producen output sin outcome [5], [6]. Cuando se aplica IA sin esa distinción, el piloto se convierte en un laboratorio permanente: hay demos, hay accuracy en notebooks, y no hay decisión de producto.
Un segundo frente de retos es organizacional. Estudios de adopción tecnológica enfatizan que el cambio falla cuando no hay sponsors claros, incentivos alineados ni enablement de usuarios finales [7]. En iniciativas de IA esto se agrava: data science suele reportar a analítica o IT; producto reporta a crecimiento o revenue; y legal/compliance entra tarde. El resultado es un silo de «equipo de IA» sin definition of done orientada a usuario y negocio.
Un tercer frente es métrico. Tableros de «número de prompts», «tokens consumidos», «accuracy del modelo» o «porcentaje de respuestas automatizadas» pueden ser útiles como indicadores técnicos, pero se vuelven vanity metrics cuando son la única narrativa de éxito ante dirección [8]. Sin vínculo a retención, conversión, costo unitario, tiempo de ciclo o NPS, la organización optimiza lo visible y no lo valioso.
En Latinoamérica, estos retos se combinan con restricciones específicas: menor densidad de talento de MLOps, stacks legacy en fintech y retail, y presión por mostrar ROI rápido ante boards. Casos públicos de plataformas de delivery, pagos y movilidad (incluyendo contextos en los que el autor ha colaborado en branding, product y change) ilustran que la diferencia entre un piloto y un sistema en producción es menos el modelo y más quién decide, con qué ritmo se itera y qué se mide [3], [9].
Este trabajo se diferencia de revisiones puramente técnicas al centrarse en el sistema de implementación como objeto de diseño. No propone un modelo nuevo; propone un método para que producto lidere el paso de exploración a operación con criterios explícitos de equipo, ritmo y métricas.
Relación con discovery continuo. Inspirado en enfoques lean y de product discovery [5], [11], el marco trata cada release de IA como un experimento de producto: la unidad de progreso no es el modelo desplegado, sino la hipótesis validada (o invalidada) con usuarios. Esto evita el sesgo de comprometimiento con un POC costoso que «ya casi está» pero no mueve comportamiento.

III. METODOLOGÍA APLICADA

La metodología aplicada se basa en un ciclo de tres capas —equipo, ritmo y métricas— ejecutado de forma iterativa desde el diseño del piloto hasta la estabilización en producción. Es reproducible: cualquier producto digital puede auditar su estado con la checklist al final de esta sección y priorizar la capa más débil.
A. El equipo que implementa (no solo el que explora). Se distingue explícitamente el equipo de exploración (investigación de modelos, POCs, evaluación offline) del equipo de implementación en producción. Este último requiere, como mínimo: (1) un product owner de IA con mandato de outcome de negocio y autoridad para priorizar backlog; (2) pairing continuo entre engineering de producto y perfiles de ML/datos, no handoffs semanales; (3) un rol de change/enablement responsable de adopción interna o de usuarios externos; y (4) una definition of done que incluya monitoreo, rollback, documentación para soporte y criterio de éxito medido en comportamiento de usuario —no solo accuracy offline [5], [10].
Incentivos y gobierno. Si el equipo de exploración se mide por papers internos o demos, y el de implementación se mide por tickets cerrados, el sistema se rompe. Se recomienda un OKR compartido (por ejemplo, adopción semanal de la capacidad de IA + movimiento de una métrica norte de negocio) y un comité corto de desbloqueo (producto + engineering + riesgo) con cadencia fija.
B. Ritmo de updates que sostiene adopción. La cadencia recomendada es semanal o biweekly de releases medibles hacia usuarios reales (o un segmento canario), con presupuesto explícito de rework post-lanzamiento. Cada release debe responder tres preguntas: ¿qué hipótesis de valor se prueba?, ¿qué señal de adopción se espera en 7–14 días?, ¿qué condición dispara rollback o pivot? Feedback loops con usuarios (entrevistas, tickets, telemetría cualitativa) se programan en el mismo sprint que el ship, no como fase posterior [6].
C. Métricas: north-star de negocio + leading indicators; veto a vanity como narrativa única. Se define una métrica norte ligada al P&L o a un outcome de producto (conversión, retención, costo por transacción, tiempo de ciclo, NPS/CSAT según el caso). Los leading indicators de adopción (uso semanal de la feature, tasa de finalización asistida, escalamiento a humano) se reportan junto a la norte —nunca en su lugar. Indicadores técnicos (latency, accuracy, costo de inferencia) viven en un tablero de salud, no en el slide de «éxito de IA» ante dirección [8].
Checklist de implementación (resumen). (1) ¿Existe un product owner de IA con mandato de outcome? (2) ¿Hay pairing product-engineering-ML en el mismo backlog? (3) ¿Hay definition of done con monitoreo y rollback? (4) ¿Hay release canario con hipótesis y señal en ≤14 días? (5) ¿Hay presupuesto de rework? (6) ¿La métrica norte es de negocio/producto? (7) ¿Las vanity metrics tienen veto como única narrativa? (8) ¿Change/enablement tiene dueño nombrado? Un «no» en tres o más ítems es señal temprana de fracaso.
Flujo piloto→producción. La Fig. 1 resume el flujo: exploración acotada → decisión de go/no-go con criterios de negocio → equipo de implementación → releases canario → estabilización con métricas norte y health → scale o kill. El punto crítico no es el modelo: es la decisión de go/no-go y la transición de ownership.
Reproducibilidad operativa. Para que otra organización aplique el marco, se recomienda un artefacto mínimo por iniciativa: (a) one-pager de hipótesis de valor y métrica norte; (b) mapa de roles del equipo de implementación con nombres y porcentaje de dedicación; (c) calendario de releases canario para las próximas seis semanas; (d) tablero dual

(negocio + salud técnica); y (e) registro de decisiones go/no-go. Sin estos cinco artefactos, el «proyecto de IA» tiende a vivir solo en slides.

Priorización entre casos de uso. Cuando hay múltiples oportunidades de IA, se puntúa cada caso en cuatro ejes (0–2): claridad de telemetría, reversibilidad del error, fuerza del ownership de producto y viabilidad de ciclo ≤14 días. Se implementa primero lo que suma ≥6. Casos con score bajo se dejan en exploración o se descartan —evitar el anti-patrón de «IA en todo» sin capacidad de delivery.

IV. RESULTADOS

Los resultados se presentan como patrones cualitativos y criterios de diagnóstico, no como ROI cuantificado de clientes. Esta elección es deliberada: los datos de impacto en Rappi, Mercado Pago, Wise y Bolt están sujetos a confidencialidad, y fabricar porcentajes invalidaría el aporte. En su lugar, se reportan lecciones transferibles observadas en contextos de product, branding y change, alineadas con evidencia pública sobre adopción y productividad [1], [3], [9].

Patrón 1 — Piloto eternizado. En organizaciones de alto crecimiento (delivery, fintech, movilidad), es frecuente que un POC demuestre viabilidad técnica y luego quede huérfano: el equipo de exploración pasa al siguiente modelo; producto no tiene capacidad ni mandato; compliance no fue involucrado. Señal temprana: más de dos ciclos de «demo a stakeholders» sin fecha de canario ni product owner nombrado. Corrección: forzar go/no-go con checklist y transferir backlog al equipo de implementación.

Patrón 2 — Adopción sin ritmo. Lanzamientos «big bang» de asistentes o recomendaciones generan un pico de uso seguido de abandono cuando no hay updates visibles, enablement ni respuesta a tickets. En contextos multi-país (típicos de plataformas LATAM y globales como las citadas), la heterogeneidad de usuarios exige canarios por segmento y un ritmo de mejoras semanal/biweekly. Señal temprana: NPS/CSAT de la feature cae mientras el tablero técnico muestra «accuracy estable».

Patrón 3 — Vanity que oculta el P&L. Equipos reportan volumen de interacciones automatizadas mientras conversión, costo unitario o tiempo de resolución no mejoran —o empeoran por rework humano. La corrección no es eliminar métricas técnicas, sino degradarlas a health metrics y elevar la narrativa de éxito a outcomes de negocio. La Tabla I resume el criterio «usar / evitar».

Criterios de priorización observados. Priorizar casos donde: (i) el workflow ya tiene telemetría confiable; (ii) el costo de error es acotado o reversible; (iii) hay un owner de producto con skin in the game; (iv) el update cycle puede ser ≤14 días. Despriorizar casos donde el único sponsor es «innovación» sin P&L, o donde legal/compliance entra después del piloto.

Señales tempranas de fracaso (síntesis). Tres o más «no» en la checklist; >60 días sin release a usuarios reales; OKRs solo de exploración; tablero ejecutivo dominado por prompts/accuracy; ausencia de rollback; change sin dueño. Estas señales son accionables antes de agotar presupuesto.

Lecciones cualitativas de contextos Rappi / Mercado Pago / Wise / Bolt. En plataformas de alto volumen (delivery, pagos, transferencias, movilidad), el branding y el change management suelen adelantarse o desalinearse respecto al product system: se comunica «IA» antes de tener canario estable, o se capacita a operaciones sobre un flujo que aún cambia cada semana. La lección transferible es sincronizar narrativa externa/interna con el ritmo real de releases: enablement sigue al canario, no lo precede con promesas no soportadas. Otra lección: en organizaciones multi-país, un único modelo «global» sin ownership local de adopción produce métricas agregadas saludables que ocultan fricción por mercado.

Antes/después en variables de proceso (sin inventar ROI). Donde el marco se aplicó con disciplina, los cambios observables típicos fueron de proceso —no cifras publicables de revenue—: reducción del tiempo entre POC aprobado y primer canario; aparición de un backlog único producto-ML; y reemplazo del slide de accuracy por un slide de outcome + health. Donde no se aplicó, el síntoma dominante fue la coexistencia de demos frecuentes y ausencia de definición de done en producción.

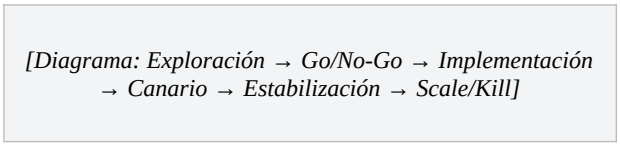


Fig. 1. Flujo piloto→producción: exploración acotada, decisión go/no-go, equipo de implementación, releases canario, estabilización con métricas norte y de salud, y decisión de scale o kill.

TABLA I. MÉTRICAS DE IA: USAR FRENTE A EVITAR (VANITY)

Parámetro / indicador	Usar (negocio / producto)	Evitar (vanity como éxito)
Adopción	Uso semanal de la capacidad de IA por usuario objetivo; tasa de	Número total de prompts o sesiones sin contexto de cohorte

	finalización del flujo asistido	
Outcome de negocio	Conversión, retención, costo unitario, tiempo de ciclo o NPS/CSAT ligado al caso	«Accuracy» offline o score del modelo como KPI ejecutivo único
Calidad operativa	Tasa de escalamiento a humano, rollback rate, latencia p95 en producción	Tokens consumidos o costo de API sin vínculo a valor entregado
Aprendizaje de producto	% de releases con hipótesis y señal medida en ≤14 días	Cantidad de demos a stakeholders o POCs abiertos

V. CONCLUSIONES

El «95% de fracaso» no es un destino tecnológico: es un patrón de implementación. Quien gana no es quien prueba el modelo más nuevo, sino quien arma el equipo correcto, sostiene el ritmo de updates y mide lo que el negocio reconoce. Para product managers y líderes de producto en Latinoamérica, la implicación práctica es clara: tratar la implementación de IA como un sistema de producto —con ownership, cadencia y métricas— y no como un proyecto de laboratorio.

Contribuciones. (1) Un marco de tres capas (equipo, ritmo, métricas) operable en organizaciones de producto digital. (2) Una checklist y señales tempranas para diagnóstico. (3) Una tabla «usar / evitar» que separa vanity de outcomes. (4) Una figura de flujo piloto→producción centrada en la decisión de go/no-go y la transición de ownership.

Limitaciones. El trabajo se basa en experiencia profesional y patrones cualitativos en contextos LATAM y de producto digital (incluyendo colaboración en branding, product y change con Rappi, Mercado Pago, Wise y Bolt); no reporta un ensayo controlado ni ROI cuantificado multi-empresa. La generalización a industrias altamente reguladas o a IA embebida en hardware requiere adaptación.

Trabajo futuro. Instrumentos de scoring de readiness de implementación; estudios longitudinales de cadencia de releases vs. adopción de features de IA; y playbooks sectoriales (fintech, retail, movilidad) que traduzcan la checklist a controles de riesgo y compliance locales.

VI. BIOGRAFÍA(S)

Pablo Carmona trabaja desde Ciudad de México en Itera & Beta AI, ayudando a equipos a implementar inteligencia artificial con impacto de negocio —no solo demos. Ha desarrollado frameworks de branding, product y change con organizaciones como Rappi, Mercado Pago, Wise y Bolt. Sus charlas y asesorías se centran en modos de fracaso de implementación, métricas de producto frente a vanity AI, y liderazgo de producto en LATAM. Habla español e inglés. LinkedIn: https://www.linkedin.com/in/pblcrmn · pablo@b-ta.ai · +52 55 1066 0830.

AGRADECIMIENTOS

El autor agradece a los equipos de producto y change con quienes ha colaborado en distintas etapas de adopción de capacidades digitales e IA, así como a la comunidad de product managers en Ciudad de México por conversaciones que ayudaron a refinar el marco aquí presentado. Los errores u omisiones son responsabilidad exclusiva del autor.

REFERENCIAS

[1] Brynjolfsson, E., Rock, D. y Syverson, C. (2021). "The productivity J-curve: How intangibles complement general purpose technologies." American Economic Journal: Macroeconomics, vol. 13, núm. 1, pp. 333–372. DOI: 10.1257/mac.20180386

[2] Ransbotham, S., Khodabandeh, S., Kiron, D., Candelon, F., Chu, M. y LaFountain, B. (2020). "Expanding AI's impact with organizational learning." MIT Sloan Management Review / Boston Consulting Group. Recuperado de https://sloanreview.mit.edu/

[3] McKinsey & Company (2023). The state of AI in 2023: Generative AI's breakout year. Recuperado el 15 de septiembre de 2026, de https://www.mckinsey.com/capabilities/quantumblack/our-insights

[4] Brynjolfsson, E. y McAfee, A. (2017). Machine, Platform, Crowd: Harnessing Our Digital Future. Nueva York: W. W. Norton. ISBN: 978-0-393-25429-7
[5] Cagan, M. (2018). Inspired: How to Create Tech Products Customers Love (2ª ed.). Hoboken, NJ: Wiley. ISBN: 978-1-119-38750-3
[6] Cagan, M. y Jones, C. (2020). Empowered: Ordinary People, Extraordinary Products. Hoboken, NJ: Wiley. ISBN: 978-1-119-69129-7
[7] Kotter, J. P. (2012). Leading Change. Boston, MA: Harvard Business Review Press. ISBN: 978-1-4221-8643-5
[8] Hubbard, D. W. (2014). How to Measure Anything: Finding the Value of Intangibles in Business (3ª ed.). Hoboken, NJ: Wiley. ISBN: 978-1-118-53927-9
[9] World Economic Forum (2023). The Future of Jobs Report 2023. Ginebra: WEF. Recuperado de https://www.weforum.org/reports/the-future-of-jobs-report-2023/
[10] Forsgren, N., Humble, J. y Kim, G. (2018). Accelerate: The Science of Lean Software and DevOps. Portland, OR: IT Revolution. ISBN: 978-1-942788-33-1
[11] Ries, E. (2011). The Lean Startup. Nueva York: Crown Business. ISBN: 978-0-307-88789-4
[12] IA Expo Internacional (2026). Convocatoria de artículos — Términos y condiciones. Recuperado el 21 de septiembre de 2026, de https://iaexpo.ai/articulos/terminos-y-condiciones