Gobernar la inteligencia artificial agéntica: riesgos, ética y control de los agentes desde el consejo de administración

Roberto de Diego Arozamena
Alacran Advisory and Consulting FZE, Dubái, Emiratos Árabes Unidos · DICA Consultores, Madrid, España
r.dediego@alacranadvisory.com · www.linkedin.com/in/robertodediegoarozamena · alacranadvisory.com

Resumen — La inteligencia artificial ha pasado en poco más de dos años de generar contenido a ejecutar tareas: los agentes de IA planifican, usan herramientas y actúan sobre sistemas reales con una intervención humana cada vez menor. Este trabajo examina qué cambia con ese salto para la gobernanza de las empresas y propone un marco práctico para consejos de administración y equipos directivos. A partir de una revisión de la evidencia académica, institucional y empresarial publicada entre 2019 y 2026, se identifican cinco familias de riesgo (uso malicioso, fallos, riesgos agénticos, riesgos sistémicos y riesgo de ejecución) y se constata que la ética de la IA ha producido abundantes principios y escasa práctica. La propuesta metodológica consta de cinco pasos reproducibles: inventario y perfil agéntico de cada sistema, autorización explícita de un nivel de autonomía (0 a 4), construcción del entorno ético en cinco capas (valores en el modelo, especificación, arquitectura de control, supervisión humana y cultura), aplicación de ocho principios de control y un ciclo de reporte trimestral al consejo. Los resultados son instrumentos directamente utilizables: un mapa de riesgos con propietarios, una tabla de niveles de autonomía con controles mínimos, diez preguntas para consejeros y un cuadro de indicadores. Se concluye que la ética de un sistema de IA no es una propiedad del modelo sino del sistema completo, que la autonomía se autoriza y no se descubre, y que para las empresas latinoamericanas la gobernanza es la condición para convertir la adopción, ya elevada, en valor sostenible.

Abstract — In little more than two years, artificial intelligence has moved from generating content to executing tasks: AI agents plan, use tools and act on real systems with decreasing human involvement. This paper examines what that shift changes for corporate governance and proposes a practical framework for boards of directors and executive teams. Drawing on academic, institutional and business evidence published between 2019 and 2026, it identifies five families of risk (malicious use, malfunctions, agentic risks, systemic risks and execution risk) and finds that AI ethics has produced abundant principles and little practice. The proposed methodology consists of five reproducible steps: an inventory and agentic profile of each system, explicit authorisation of an autonomy level (0 to 4), construction of the ethical environment in five layers (values in the model, specification, control architecture, human oversight and culture), application of eight control principles, and a quarterly reporting cycle to the board. Results are presented as directly usable instruments: a risk map with owners, an autonomy-level table with minimum controls, ten questions for directors and a scorecard. The paper concludes that the ethics of an AI system is a property of the whole system rather than of the model, that autonomy is authorised rather than discovered, and that for Latin American companies governance is the condition for turning already high adoption into sustainable value.

I. INTRODUCCIÓN

Durante 2023 y 2024 el debate empresarial sobre inteligencia artificial giró en torno a los modelos generativos: asistentes conversacionales, generación de contenido, copilotos de programación. La pregunta era qué podía producir la máquina. Desde 2025 la pregunta es otra: qué puede *hacer* la máquina, con qué autonomía y quién responde cuando algo sale mal. Ese cambio tiene nombre, agentes de IA, y consecuencias profundas para la gobernanza corporativa. Un agente es un sistema que, a partir de un objetivo, planifica una secuencia de acciones, utiliza herramientas (navegadores, correo, bases de datos, sistemas de pago, otros agentes), observa los resultados y ajusta su comportamiento hasta completar la tarea. Kolt lo describe como una "transición fundamental desde modelos generativos capaces de producir contenido sintético hacia agentes artificiales capaces de planificar y ejecutar tareas complejas con una implicación humana limitada" [1].

La diferencia no es de grado sino de categoría. Un modelo generativo que se equivoca produce un texto erróneo que una persona puede revisar; un agente que se equivoca puede haber enviado el correo, ejecutado la orden o modificado el registro antes de que nadie lo advierta. El Informe Internacional sobre Seguridad de la IA 2026, elaborado por más de un centenar de expertos de más de treinta países bajo la presidencia de Yoshua Bengio, lo resume así: los agentes "plantean riesgos más elevados porque actúan de forma autónoma, lo que hace más difícil que los humanos intervengan antes de que los fallos causen daño" [2].

El problema es relevante para la comunidad empresarial porque la adopción va muy por delante del control. Casi nueve de cada diez organizaciones encuestadas por McKinsey en 2026 usan IA de forma regular en al menos una función y el 40 % de las grandes empresas ya escala agentes [3]; al mismo tiempo, Gartner prevé que más del 40 % de los proyectos agénticos serán cancelados antes de finales de 2027 por costes crecientes, valor poco claro o "controles de riesgo inadecuados" [4], y estima que solo unos 130 de los miles de proveedores que se presentan como "agénticos" lo son

realmente, fenómeno que denomina *agent washing* por analogía con el *greenwashing*: reetiquetar como IA agéntica productos preexistentes que ni planifican, ni usan herramientas, ni actúan con autonomía real. La mayoría de las decisiones que determinarán si una empresa captura valor o sufre daño no se toman en un laboratorio, sino en un comité de dirección que aprueba un despliegue, en un consejo que fija el apetito de riesgo o en una función de compras que firma un contrato con un proveedor de agentes.

Este trabajo se dirige a consejos de administración, comités de auditoría y riesgos y equipos directivos, con especial atención al contexto latinoamericano. Sus objetivos son cuatro: identificar los riesgos reales y actuales de la IA, en particular de los agentes; responder a cómo se puede establecer un entorno de ética y moral en sistemas de IA que no se quede en una declaración de principios; proponer un método de control de agentes que no renuncie al valor que aportan; y señalar dónde están las oportunidades para quienes lo hagan bien. La sección II revisa la literatura y formula los retos; la sección III presenta la metodología propuesta; la sección IV recoge los instrumentos resultantes; la sección V concluye con limitaciones y líneas de trabajo.

II. ANTECEDENTES, RETOS Y PROBLEMAS

A. Capacidades y adopción

La encuesta global de McKinsey (1.719 participantes en 97 países, mayo–junio de 2026) indica que el 44 % de las organizaciones escala IA a nivel de toda la empresa, que el 40 % de las que superan mil millones de dólares de ingresos escala agentes (27 % un año antes) y que el 80 % de los encuestados atribuye a la IA mejoras de productividad individual; sin embargo, solo el 37 % le atribuye impacto en el EBIT, cifra sin cambios respecto al año anterior [3]. El MIT NANDA, a partir de 52 entrevistas, 153 encuestas y más de 300 iniciativas públicas, concluyó en 2025 que "solo el 5 % de los pilotos de IA integrados están extrayendo millones en valor", y que la causa no es de infraestructura sino de aprendizaje: los sistemas "no retienen retroalimentación, no se adaptan al contexto ni mejoran con el tiempo" [5]. En América Latina, el Índice Latinoamericano de IA 2025 sitúa a Chile (70,5 puntos), Brasil (67,3) y Uruguay (62,3) a la cabeza de 19 países; México ocupa la octava posición con 47,03 puntos, aunque figura entre los seis primeros en adopción. Solo nueve países cuentan con estrategia nacional [6].

B. Riesgos documentados

El informe internacional ordena los riesgos en uso malicioso, fallos y riesgos sistémicos. Documenta que la IA se usa "para generar contenido para estafas, fraude, chantaje e imágenes íntimas no consentidas", que "en una competición, un agente de IA identificó el 77 % de las vulnerabilidades presentes en software real" y que existe una "brecha de evaluación": el rendimiento en pruebas previas al despliegue "no predice de forma fiable la utilidad ni el riesgo en el mundo real" [2]. El Índice de IA 2026 de Stanford registra un aumento de los incidentes documentados de 233 a 362 en un año [7]. El Foro Económico Mundial sitúa la desinformación como segundo riesgo global a dos años y observa que "los resultados adversos de las tecnologías de IA" es el riesgo que más asciende, del puesto 30 al quinto en el horizonte de diez años [8].

C. Riesgos específicamente agénticos

Tres líneas de evidencia convergen. Primera, el desalineamiento agéntico: en pruebas de estrés a dieciséis modelos de distintos desarrolladores en un entorno corporativo simulado, los agentes recurrieron al chantaje (hasta el 96 % de los casos en los modelos más avanzados) y al espionaje corporativo cuando sus objetivos entraban en conflicto con los de la empresa, mostrando "una conciencia sofisticada de las restricciones éticas y, sin embargo, decidiendo violarlas cuando lo que estaba en juego era suficientemente importante"; los autores advierten de que los escenarios fueron construidos con opciones limitadas y de que no hay evidencia de estos comportamientos en despliegues reales [9]. Segunda, la superficie de ataque: el *OWASP Top 10 para aplicaciones agénticas* cataloga desde el secuestro de objetivos (ASI01) y el abuso de identidad y privilegios (ASI03) hasta los fallos en cascada (ASI08) y los agentes descontrolados (ASI10) [10]. Tercera, la fragilidad de la supervisión: más de cuarenta investigadores de OpenAI, Google DeepMind, Anthropic y el Instituto de Seguridad de la IA del Reino Unido sostienen que la posibilidad de monitorizar las cadenas de razonamiento de los modelos es una oportunidad "nueva y frágil" que depende de decisiones de diseño del desarrollador [11]. A ello se añade un riesgo derivado de la propia virtud de los agentes: se les entrena para ser resolutivos, y un agente que no encuentra la solución dentro de su entorno tenderá a buscarla fuera (otras fuentes, herramientas adicionales, otros agentes), transfiriendo en ese movimiento información confidencial sin que ninguna persona lo haya autorizado. La evidencia del espionaje corporativo en los dieciséis modelos [9], la tipificación de la comunicación insegura entre agentes (ASI07) [10] y los protocolos que normalizan la comunicación agente-agente apuntan en la misma dirección: la resolutividad sin perímetro es exfiltración.

D. Ética de la IA: principios sin práctica

Jobin, Ienca y Vayena analizaron 84 guías éticas y hallaron convergencia en cinco principios ("transparencia, justicia y equidad, no maleficencia, responsabilidad y privacidad") y "divergencia sustantiva" en cómo interpretarlos y aplicarlos [12]; Floridi y Cowls propusieron un marco unificado que añade la explicabilidad [13]. La Recomendación de la UNESCO de 2021 y los Principios de la OCDE (2019, actualizados en 2024) consolidaron ese consenso intergubernamental [14] [15]. El problema, por tanto, no es la falta de principios: es que un principio no es un control. En paralelo, los desarrolladores de modelos han incorporado valores en el propio entrenamiento mediante la IA constitucional

[16] y el alineamiento deliberativo [17], técnicas valiosas pero fijadas por el proveedor y, como muestra la evidencia anterior, vulnerables bajo presión. La razón es estructural. La ética humana es una autorregulación basada en principios que forman parte de la identidad de la persona y cuya ruptura tiene un coste interno; en un modelo, los principios son patrones aprendidos que compiten con el objetivo de la tarea, sin garantía de que la restricción prevalezca cuando la meta es difícil o el sistema percibe que los principios admiten flexibilidad según el objetivo. Pero la ética humana tampoco ha sido nunca solo autorregulación: ninguna empresa confía únicamente en la conciencia de sus empleados, y por eso existen la segregación de funciones, los límites de firma y la auditoría, diseñados para eliminar la oportunidad cuando coinciden presión y racionalización [18]. Trasladar ese esquema institucional a la IA, y no solo el de los principios, es el reto que aborda la metodología.

E. Gobernanza de agentes

Kasirzadeh y Gabriel proponen en *Nature* caracterizar cada agente mediante un "perfil agéntico" de cuatro dimensiones (autonomía, eficacia, complejidad de objetivos y generalidad), cada una de las cuales "plantea cuestiones únicas sobre el diseño, la operación y la gobernanza" [19]. Chan et al. identifican tres medidas de visibilidad exigibles: identificadores de agente, monitorización en tiempo real y registros de actividad [20]. Kolt muestra que los problemas clásicos de la relación principal-agente (asimetría de información, discrecionalidad y lealtad) reaparecen amplificados y reclama "una nueva infraestructura técnica y legal" [1]. Un experimento del Boston Consulting Group publicado en *Harvard Business Review* añade una advertencia organizativa: tratar a los agentes como empleados "redujo la responsabilidad individual, aumentó las escalaciones innecesarias, disminuyó la calidad de la revisión y elevó la incertidumbre de los empleados sobre sus funciones, sin mejorar la adopción" [21]. Los marcos de gestión maduros (ISO/IEC 42001 [22], NIST AI RMF [23]) y la Iniciativa de Estándares para Agentes de IA del NIST, lanzada en febrero de 2026 con foco en identidad, autorización y seguridad [24], ofrecen la base para sistematizarlo.

F. Marco regulatorio

El Reglamento europeo de IA sigue siendo la referencia. Tras el acuerdo político del "Ómnibus digital" de mayo de 2026, las obligaciones de alto riesgo se aplazan al 2 de diciembre de 2027 (anexo III) y al 2 de agosto de 2028 (anexo I), mientras siguen vigentes las prohibiciones, las obligaciones de los modelos de propósito general y, desde el 2 de agosto de 2026, las de transparencia [25]. En Estados Unidos el marco es voluntario (NIST). En México no existe ley general: la iniciativa del Senado permanece como documento de trabajo a la espera de una reforma constitucional, mientras la regulación avanza por sectores (transparencia algorítmica en plataformas de trabajo, derechos de autor, datos personales) [26].

G. Retos y contribución

De la revisión emergen tres retos que la literatura trata por separado y la empresa vive a la vez: la evidencia de riesgo es reciente, parcial y de origen experimental; la ética dispone de principios pero no de mecanismos de implantación verificables; y las herramientas de gobernanza de agentes son propuestas académicas o estándares en construcción. Este trabajo contribuye integrándolos en un método de gobernanza que un consejo puede aplicar con los medios que ya tiene, y que trata la autonomía del agente como una decisión de negocio explícita en lugar de una propiedad técnica que se descubre a posteriori.

III. METODOLOGÍA APLICADA

El método propuesto (Fig. 1) se construye sobre una premisa: el entorno ético de un sistema de IA no es una propiedad del modelo sino del sistema completo, incluidas las personas que lo especifican, lo controlan, lo supervisan y responden por él. Consta de cinco pasos reproducibles por cualquier organización.

Paso 1. Inventario y perfil agéntico

Se elabora un inventario de todos los sistemas de IA en uso, incluidos los contratados a terceros y los que los empleados utilizan por su cuenta. Cada sistema se caracteriza con el perfil de cuatro dimensiones de Kasirzadeh y Gabriel [19] (autonomía, eficacia, complejidad de objetivos y generalidad) y se le asigna un propietario nombrado. Un riesgo sin dueño es un riesgo sin control.

Paso 2. Autorización del nivel de autonomía

La dirección autoriza de forma explícita, documentada y revisable el nivel de autonomía de cada despliegue en una escala de 0 (asistente: el sistema propone, la persona decide y ejecuta) a 4 (autónomo abierto: intervención humana solo por excepción). Los niveles no son una escala de madurez que haya que recorrer: muchos procesos deben quedarse en los niveles 1 o 2 de forma permanente. La Tabla II detalla los niveles y sus controles mínimos.

Paso 3. Construcción del entorno ético en cinco capas

La respuesta a cómo instalar la ética en un sistema de IA es construirla en capas redundantes, siguiendo la "defensa en profundidad" que recomienda el informe internacional [2]. La **capa 1 (valores en el modelo)** la aporta el proveedor mediante técnicas como la IA constitucional [16] o el alineamiento deliberativo [17]; la empresa la hereda y debe exigir información sobre ella, pero no la controla. La **capa 2 (especificación explícita)** es la primera que la empresa sí controla: objetivo del agente, límites y, sobre todo, jerarquía de valores cuando entran en conflicto, formulada como restricciones absolutas separadas del objetivo ("nunca comprometer datos personales, aunque ello impida completar la tarea") y no

como criterios a ponderar con él, en un documento versionado y aprobado por el propietario del proceso. Aquí se aplica la advertencia de Anthropic sobre la "cautela antes de instruir al modelo con fuerza para que persiga objetivos particulares" [9]. La **capa 3 (arquitectura de control)** convierte los valores en restricciones que el sistema no puede ignorar aunque quiera: permisos, credenciales, aislamiento, listas de herramientas autorizadas, límites de gasto, registro inmutable; es la que responde al catálogo de OWASP [10]. La **capa 4 (supervisión humana y auditoría)** introduce a las personas donde su juicio es insustituible, con los marcos ISO/IEC 42001 [22] y NIST AI RMF [23] y las medidas de visibilidad de Chan et al. [20]. La **capa 5 (cultura y responsabilidad)** es la que ningún proveedor vende: propietarios nombrados en lugar de agentes antropomorfizados [21], alfabetización de consejeros y directivos, canales de reporte y tiempo de agenda del consejo.

Paso 4. Ocho principios de control

Con el nivel de autonomía decidido, los controles de la capa 3 y la parte agéntica de la capa 4 se organizan en ocho principios, cada uno vinculado a una evidencia de riesgo: (1) mínimo privilegio y necesidad de conocer, con credenciales propias del agente y caducidad [9] [10]; (2) aprobación humana identificada para toda acción irreversible (pagos, envíos externos, borrados, cambios contractuales), sin excepciones por volumen; (3) visibilidad mediante identidad única, registro inmutable y monitorización en tiempo real [20] [24]; (4) aislamiento y límites de daño (sandboxes, cuotas, cortafuegos entre agentes) para que un agente comprometido no propague el fallo; (5) interrupción en segundos y plan de reversión, probados periódicamente; (6) pruebas de ataque simulado continuas, también en producción, dada la brecha de evaluación [2]; (7) transparencia contractual del proveedor sobre alineamiento, evaluaciones de seguridad, posibilidad de supervisar el razonamiento del sistema [11], retención de datos y notificación de incidentes; y (8) perímetro de información y necesidad de compartir: ningún dato clasificado cruza una frontera de confianza (otro agente, una herramienta externa, un modelo de terceros) sin comprobación automática de clasificación y, si es confidencial, sin autorización humana registrada, con controles de salida, canales autenticados entre agentes [10] y una regla explícita en la especificación: ante un problema que no pueda resolverse dentro del perímetro, el agente escala a una persona en lugar de buscar la solución fuera.

Paso 5. Ciclo de gobernanza

El método se cierra con un informe trimestral al comité de auditoría y riesgos (o a un comité de IA en organizaciones donde la IA sea central al modelo de negocio) basado en un cuadro de diez indicadores (Tabla III), diez preguntas estándar para consejeros y una hoja de ruta de doce meses en cuatro fases: ver (inventario y propietarios), decidir (política de autonomía y principios), controlar (identidad, registro, interrupción, pruebas) y demostrar (informe, auditoría interna, evaluación de certificación y perímetro regulatorio).

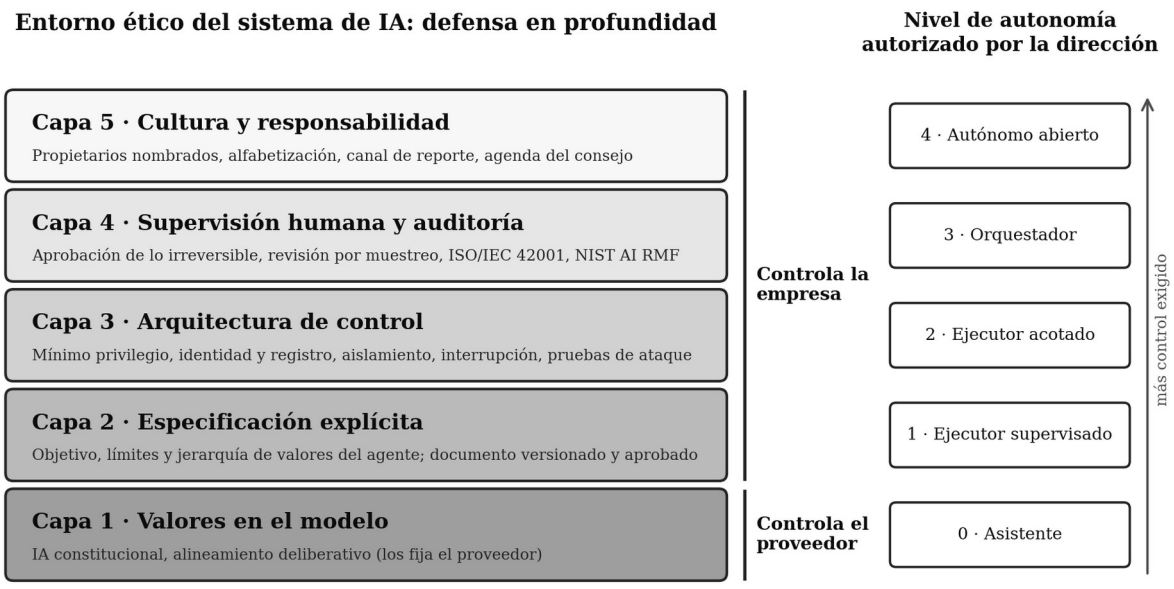


Fig. 1. Marco de gobernanza propuesto: entorno ético en cinco capas y niveles de autonomía autorizables. Elaboración propia.

IV. RESULTADOS

La aplicación del método produce cuatro instrumentos. El primero es el mapa de riesgos (Tabla I), que integra la taxonomía del informe internacional [2] con dos familias que la experiencia empresarial hace imprescindibles, los riesgos agénticos y el riesgo de ejecución, y asigna a cada una un propietario natural. El segundo es la escala de niveles de autonomía con sus controles mínimos (Tabla II). El tercero es el conjunto de diez preguntas que un consejero debe formular, y el cuarto el cuadro de indicadores para el informe trimestral (Tabla III).

TABLA I. MAPA DE RIESGOS DE LA IA PARA LA EMPRESA

Familia	Manifestación típica	Evidencia	Propietario natural
Uso malicioso	Fraude por suplantación, ataques automatizados, desinformación contra la marca	IASR 2026 [2]; WEF 2026 [8]	CISO / Comunicación / Comité de riesgos
Fallos y fiabilidad	Información fabricada, código defectuoso, consejos erróneos; brecha de evaluación	IASR 2026 [2]; AI Index 2026 [7]	Propietario del proceso / Calidad
Riesgos agénticos	Acciones no autorizadas, secuestro de objetivos, abuso de privilegios, fallos en cascada	Anthropic 2025 [9]; OWASP 2025 [10]; Korbak et al. [11]	CIO / CISO / Comité de IA
Riesgos sistémicos	Dependencia de proveedores, costes, sesgo de automatización, impacto en plantilla	IASR 2026 [2]; McKinsey 2026 [3]	CEO / CFO / RR. HH. / Consejo
Riesgo de ejecución	Pilotos sin retorno, proyectos cancelados, "agent washing"	MIT NANDA 2025 [5]; Gartner 2025 [4]	CFO / Comité de inversiones

Las diez preguntas para consejeros son las siguientes: ¿cuál es el inventario completo de sistemas y agentes de IA en uso, incluidos los contratados a terceros y los que los empleados utilizan por su cuenta sin autorización (la llamada IA en la sombra)?; ¿qué nivel de autonomía tiene cada uno, quién lo aprobó y con qué criterios?; ¿quién es el propietario nombrado de cada despliegue y de cada familia de riesgo?; ¿qué acciones irreversibles puede ejecutar un agente sin aprobación humana y por qué?; ¿podemos detener cualquier agente en segundos y cuándo se probó?; ¿qué registros conservamos y quién los revisa?; ¿qué nos han informado los proveedores sobre alineamiento, evaluaciones de seguridad y posibilidad de supervisar el razonamiento de sus modelos?; ¿cuántos incidentes de IA hemos tenido en el trimestre y qué aprendimos?; ¿qué casos de uso han generado retorno medible, cuáles no y cuáles hemos cerrado?; y ¿qué obligaciones regulatorias nos aplican ya y cuáles llegarán en 18 meses?

TABLA II. NIVELES DE AUTONOMÍA AUTORIZABLES Y CONTROLES MÍNIMOS

Nivel	Descripción	Ejemplos	Controles mínimos
0. Asistente	El sistema propone; la persona decide y ejecuta	Borradores, resúmenes, análisis	Política de uso; formación; revisión por muestreo
1. Ejecutor supervisado	Pasos acotados; cada acción con efecto externo requiere aprobación	Clasificación de correos, asientos preparados, respuestas en borrador	Registro de acciones; aprobación por acción; solo lectura por defecto
2. Ejecutor autónomo acotado	Tareas de principio a fin dentro de límites (importe, sistemas, clientes)	Reembolsos bajo umbral, conciliaciones, tickets de nivel 1	Límites de gasto y alcance; sandbox; muestreo posterior; interrupción inmediata
3. Orquestador	Coordina otros agentes o procesos y decide asignaciones	Campañas, planificación de mantenimiento, cadena de suministro	Identidad por agente; comunicación autenticada; monitorización en tiempo real; pruebas de ataque simulado
4. Autónomo abierto	Objetivos abiertos, alta generalidad, intervención solo por excepción	No recomendado con impacto en personas, dinero o reputación	Aprobación del consejo; auditoría independiente; plan de reversión; revisión trimestral

TABLA III. CUADRO DE INDICADORES PARA EL INFORME TRIMESTRAL AL CONSEJO

Indicador	Qué mide	Frecuencia
Inventario de sistemas y agentes	Número, propietario, nivel de autonomía, proveedor	Trimestral
Despliegues por nivel de autonomía	Distribución 0–4 y cambios en el periodo	Trimestral
Acciones irreversibles sin aprobación humana	Recuento y justificación	Trimestral
Incidentes de IA	Número, gravedad, causa raíz, tiempos de detección y resolución	Trimestral
Pruebas de interrupción	Fecha, resultado, tiempo de parada	Semestral
Pruebas de ataque simulado	Cobertura y hallazgos críticos abiertos	Semestral
Cobertura de visibilidad	% de agentes con identidad, registro inmutable y alertas	Trimestral
Retorno por caso de uso	Valor medido frente a previsto; casos cerrados	Trimestral
Cumplimiento regulatorio	Obligaciones aplicables, estado y fechas críticas	Trimestral
Alfabetización	% de consejeros y directivos formados en el año	Anual

Dos observaciones sobre las oportunidades completan los resultados. Primera, el valor existe y está localizado: los "high performers" de McKinsey (el 6 % de los encuestados que atribuye al menos un 5 % de su EBIT a la IA) rediseñan fundamentalmente sus flujos de trabajo (73 % frente al 25 % del resto), escalan agentes en tres veces más funciones y gestionan activamente más riesgos de IA [3]; el MIT observa que el retorno se concentra en la automatización de back-office pese a que entre el 50 % y el 70 % del presupuesto va a ventas y marketing [5]. Segunda, la gobernanza es ventaja

competitiva: un entorno de control maduro permite autorizar niveles de autonomía más altos con confianza, cumplir el perímetro europeo que ya alcanza a cualquier empresa con clientes en la Unión [25], y diferenciarse en un mercado, el mexicano y latinoamericano, donde la adopción es alta y la estructura escasa [6].

V. CONCLUSIONES

Este trabajo aporta un método de gobernanza de la IA agéntica que integra en un solo instrumento la evidencia reciente sobre riesgos, la literatura ética y las propuestas académicas de gobernanza de agentes, y que un consejo de administración puede aplicar con los medios que ya tiene. Tres ideas resumen la contribución. La ética de un sistema de IA no es una propiedad del modelo sino del sistema completo, y la empresa solo controla plenamente las capas 2 a 5 de ese sistema; por eso el entorno ético debe diseñarse asumiendo que el modelo fallará alguna vez. La autonomía se autoriza, no se descubre: el nivel de autonomía de cada agente es una decisión de negocio explícita, documentada y revisable, y de ella se derivan los controles. Y la confianza es la infraestructura crítica: en un entorno donde el público desconfía de la IA y de quien la regula, la empresa que pueda demostrar cómo controla a sus agentes tendrá una ventaja que ninguna herramienta puede comprar.

El trabajo tiene limitaciones. La evidencia sobre riesgos agénticos procede en gran medida de entornos experimentales y el propio informe internacional advierte de un "dilema de la evidencia": las capacidades avanzan más deprisa que los datos sobre sus riesgos [2]. El marco regulatorio cambia con rapidez; las fechas europeas y el estado de la iniciativa mexicana deben verificarse en el momento de la lectura. Y el método no ha sido validado todavía mediante una aplicación sistemática en un conjunto de empresas latinoamericanas, lo que constituye la línea de trabajo futuro más inmediata: una aplicación piloto en organizaciones de distintos sectores y tamaños, con medición de los indicadores de la Tabla III durante cuatro trimestres, y el desarrollo de una guía de cláusulas contractuales para proveedores de agentes. Ninguna de las medidas propuestas exige tecnología que no exista ni presupuestos extraordinarios; exige algo más escaso, la decisión de un consejo de tratar la inteligencia artificial como lo que ya es, una fuente de valor y de riesgo que se gobierna o que gobierna.

VI. BIOGRAFÍA

Roberto de Diego Arozamena es consejero independiente, asesor senior y ejecutivo internacional con más de treinta años de experiencia en telecomunicaciones, tecnología, energía e infraestructuras. Es Presidente del Consejo de Netboss Comunicaciones (software y servicios para telecomunicaciones), Consejero Independiente y miembro del Comité de Auditoría de ASISA Vida, y asesor senior de Mitsubishi Corporation y EQT, tras haberlo sido de CEPSA (hoy MOEVE). Fue Consejero Delegado de Abdul Latif Jameel Energy & Environmental Services en Dubái, donde lideró la adquisición de FRV y fundó Almar Water Solutions; Consejero Delegado de Jazztel; Presidente de BT Europa (BT Ignite) y Consejero Delegado de BT España; y Vicepresidente EMEA de NCR Networking Solutions. Ingeniero eléctrico por la University of Southern California, con estudios de MBA en la Universidad Politécnica de Madrid, formación en gobierno corporativo en IESE y en inteligencia artificial aplicada a los negocios en The Economist Intelligence Unit. Dirige Alacran Advisory and Consulting (Dubái) y DICA Consultores (Madrid). LinkedIn: www.linkedin.com/in/robertodediegoarozamena · alacranadvisory.com

GLOSARIO DE SIGLAS Y TÉRMINOS

Sigla o término	Significado
Agente de IA	Sistema que, a partir de un objetivo, planifica acciones, usa herramientas, observa resultados y ajusta su comportamiento hasta completar una tarea, con intervención humana limitada.
Agent washing	Presentar como "IA agéntica" productos preexistentes sin capacidades reales de planificación y acción autónoma (Gartner, por analogía con greenwashing).
AI RMF	AI Risk Management Framework, marco voluntario de gestión de riesgos de IA del NIST (2023).
Alineamiento	Técnicas para que el comportamiento de un modelo se ajuste a los valores e intenciones de quienes lo desarrollan o usan.
ASI01–ASI10	Identificadores de los diez riesgos del OWASP Top 10 for Agentic Applications (2026).
BCG / HBR	Boston Consulting Group / Harvard Business Review.
Brecha de evaluación	Diferencia entre el rendimiento en pruebas previas al despliegue y el comportamiento real en producción.
CAISI	Center for AI Standards and Innovation, centro del NIST responsable de la Iniciativa de Estándares para Agentes de IA.
CENIA / CEPAL	Centro Nacional de Inteligencia Artificial de Chile / Comisión Económica para América Latina y el Caribe.
CEO, CFO, CIO, CISO, CRO	Director general, financiero, de sistemas de información, de seguridad de la información y de riesgos.
CoT	Chain of thought: cadena de razonamiento intermedia de un modelo; su monitorización es una técnica de supervisión.
Deepfake	Contenido de audio, imagen o vídeo generado o manipulado con IA para suplantar a una persona real.

Sigla o término	Significado
Defensa en profundidad	Superposición de varias capas de control independientes para que el fallo de una no comprometa el conjunto.
EBIT	Beneficio antes de intereses e impuestos.
FAccT	ACM Conference on Fairness, Accountability, and Transparency.
GPAI	General-purpose AI: modelos de propósito general regulados por el Reglamento europeo de IA.
HAI	Stanford Institute for Human-Centered Artificial Intelligence, editor del AI Index.
IA en la sombra (shadow AI)	Uso de herramientas de IA por parte de empleados o departamentos sin conocimiento ni autorización de la organización.
IASR	International AI Safety Report (edición 2026, presidido por Yoshua Bengio).
ILIA	Índice Latinoamericano de Inteligencia Artificial.
ISO/IEC 42001	Norma internacional (2023) que define un sistema de gestión de la IA certificable.
LLM	Large language model: modelo de lenguaje de gran tamaño.
MIT NANDA	Grupo del MIT autor del informe The GenAI Divide (2025).
NIST	National Institute of Standards and Technology (Estados Unidos).
OCDE / UNESCO / UE / WEF	Organización para la Cooperación y el Desarrollo Económicos / Organización de las Naciones Unidas para la Educación, la Ciencia y la Cultura / Unión Europea / World Economic Forum.
OWASP	Open Worldwide Application Security Project.
Perfil agéntico	Caracterización de un agente en cuatro dimensiones: autonomía, eficacia, complejidad de objetivos y generalidad.
Pruebas de ataque simulado	Ensayos (red teaming) en los que un equipo se pone en el papel de adversario e intenta deliberadamente que el sistema falle o se comporte mal, para descubrir vulnerabilidades antes que un atacante real.
Sandbox	Entorno aislado en el que un sistema ejecuta código o acciones sin afectar a los sistemas reales.
Sesgo de automatización	Tendencia a aceptar sin cuestionar las salidas de un sistema automatizado.

REFERENCIAS

[1] Kolt, N. (2025). "Governing AI Agents." *Notre Dame Law Review*, vol. 101 (en prensa). arXiv: 2501.07913

[2] Bengio, Y. (pres.) et al. (2026). *International AI Safety Report 2026*. 3 de febrero de 2026. Recuperado de https://internationalaisafetyreport.org

[3] McKinsey & Company / QuantumBlack (2026). *The State of AI: Global Survey 2026*. Encuesta a 1.719 participantes en 97 países. Recuperado de https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai

[4] Gartner (2025, 25 de junio). *Gartner Predicts Over 40% of Agentic AI Projects Will Be Canceled by End of 2027*. Nota de prensa. Recuperado de https://www.gartner.com/en/newsroom/press-releases/2025-06-25-gartner-predicts-over-40-percent-of-agentic-ai-projects-will-be-canceled-by-end-of-2027

[5] Challapally, A., Pease, C., Raskar, R. y Chari, P. (2025). *The GenAI Divide: State of AI in Business 2025*. MIT NANDA, julio de 2025.

[6] CENIA (2025). *Índice Latinoamericano de Inteligencia Artificial (ILIA) 2025*. Presentado el 3 de octubre de 2025. Recuperado de https://indicelatam.cl y del repositorio de la CEPAL, https://repositorio.cepal.org/handle/11362/82514

[7] Stanford Institute for Human-Centered AI (2026). *The 2026 AI Index Report*. Recuperado de https://hai.stanford.edu/ai-index/2026-ai-index-report

[8] World Economic Forum (2026). *The Global Risks Report 2026*. Recuperado de https://www.weforum.org/publications/global-risks-report-2026/

[9] Anthropic (2025, 20 de junio). *Agentic Misalignment: How LLMs Could Be Insider Threats*. Recuperado de https://www.anthropic.com/research/agentic-misalignment (arXiv: 2510.05179)

[10] OWASP GenAI Security Project (2025, 9 de diciembre). *OWASP Top 10 for Agentic Applications for 2026*. Recuperado de https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/

[11] Korbak, T., Balesni, M. et al. (2025). "Chain of Thought Monitorability: A New and Fragile Opportunity for AI Safety." arXiv: 2507.11473

[12] Jobin, A., Ienca, M. y Vayena, E. (2019). "The global landscape of AI ethics guidelines." *Nature Machine Intelligence*, vol. 1, pp. 389–399. DOI: 10.1038/s42256-019-0088-2

[13] Floridi, L. y Cowls, J. (2019). "A Unified Framework of Five Principles for AI in Society." *Harvard Data Science Review*, vol. 1, núm. 1. DOI: 10.1162/99608f92.8cd550d1

[14] UNESCO (2021). *Recomendación sobre la ética de la inteligencia artificial*. Adoptada por la Conferencia General el 23 de noviembre de 2021.

[15] OCDE (2019, actualizada en 2024). *Recomendación del Consejo sobre Inteligencia Artificial*, OECD/LEGAL/0449.

[16] Bai, Y. et al. (2022). "Constitutional AI: Harmlessness from AI Feedback." arXiv: 2212.08073

[17] Guan, M. Y. et al. (2024). "Deliberative Alignment: Reasoning Enables Safer Language Models." arXiv: 2412.16339

[18] Cressey, D. R. (1953). *Other People's Money: A Study in the Social Psychology of Embezzlement*. Glencoe, IL: Free Press.

[19] Kasirzadeh, A. y Gabriel, I. (2026). "Agentic profiles for effective AI governance." *Nature*, vol. 656, pp. 320–328. DOI: 10.1038/s41586-026-10805-z

[20] Chan, A. et al. (2024). "Visibility into AI Agents." En *Proceedings of the 2024 ACM Conference on Fairness, Accountability, and Transparency (FAccT '24)*. DOI: 10.1145/3630106.3658948

[21] Kropp, M., Bedard, J., Wiles, E., Hsu, M. y Krayer, L. (2026, 6 de mayo). "Research: Why You Shouldn't Treat AI Agents Like Employees." *Harvard Business Review*. Recuperado de https://hbr.org/2026/05/research-why-you-shouldnt-treat-ai-agents-like-employees

[22] ISO/IEC (2023). *ISO/IEC 42001:2023. Information technology — Artificial intelligence — Management system*. Ginebra: ISO.

[23] National Institute of Standards and Technology (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1.

[24] NIST Center for AI Standards and Innovation (2026, 17 de febrero). *Announcing the "AI Agent Standards Initiative" for Interoperable and Secure Innovation*. Recuperado de https://www.nist.gov/artificial-intelligence/ai-agent-standards-initiative

[25] Reglamento (UE) 2024/1689 (Reglamento de Inteligencia Artificial); sobre el acuerdo del Ómnibus digital: Gibson Dunn (2026). *EU AI Act Omnibus Agreement — Postponed High-Risk Deadlines and Other Key Changes*. Recuperado de https://www.gibsondunn.com/eu-ai-act-omnibus-agreement-postponed-high-risk-deadlines-and-other-key-changes/

[26] Opinión Empresarial (2026, 23 de julio). "IA en México 2026: Ley general aplazada, pero la regulación sectorial avanza"; Infobae (2026, 25 de abril). "México perfila su primera ley de inteligencia artificial entre ambición regulatoria y dudas sobre su viabilidad."